

SUPPLEMENT · ROUND 2 FINDINGS

实时 CPU 语音转换 补充分析 v2

Real-time CPU Voice Conversion

Round 2 Supplement — Better Quality at the Same 100 MB

本补充报告是对 v1 主报告（realtime-cpu-vc-tech-brief.pdf）的延伸，覆盖第二轮调研的 6 个新仓库：**OpenVoice v2**、**FreeVC**、**GPT-SoVITS（小配置）**、**Applio（RVC fork）**、**F5-TTS**、**CosyVoice2**。在保留 v1 的 TinyVC 推理主线（9.36M 参数、~36MB FP32、Apache 2.0）的前提下，本补充提出一套 **v2 混合架构**，引入 OpenVoice v2 的 256 维 ReferenceEncoder（0.76M）替换 kNN 检索 + OpenVoice ResidualCoupling flow（8.7M）做学习式说话人解耦 + F5-TTS 的 Vocos 声码器（13M，ONNX-ready）替换 TinyVC 的 DDSP——预期把说话人相似度从 v1 的 85–90% 提升到 88–93%，音质从“薄”升级到“丰满”，常驻内存仍 ~**85MB**，全部命中 100MB / 300–500ms 硬指标。

6本轮新调研仓库 / Repos
analyzed**32.7M**OpenVoice v2 总参数 /
Total params**0.76M**推荐替换 kNN 的 Speaker
Enc**~88-93%**v2 预期相似度 / Expected
SIM

一、Round 2 执行摘要 Executive Summary

KICKER · WHAT CHANGED FROM v1

v1 主报告的结论是：以 **TinyVC** (Apache 2.0, 9.36M 推理参数, 36MB FP32 / 18MB FP16, 已有 ONNX 导出与 SOLA 流式) 为推理主线, 配合 PocketTTS 借鉴的 StreamingConv1d 与 INT8 量化代码, 可以在 x86 CPU 上做到 ~370ms 端到端延迟、~85-90% 说话人相似度、~85-95MB 常驻内存。但 v1 有两个**公认弱点**: (a) kNN-VC 检索的相似度上限在 90% 附近, 与 RVC (90-95%) 和 GPT-SoVITS / F5-TTS (90-95%+) 相比偏低; (b) DDSP 加法合成声码器的音质偏“薄”, 缺少 HiFi-GAN 系列的丰满感。本补充的目标是在**不破坏 100MB / CPU / 实时**这三个硬约束的前提下, 尽量补齐这两块短板。

本轮调研的 6 个仓库按“能不能进运行时”分三档: **第一档可借鉴模块**——OpenVoice v2 与 F5-TTS; **第二档仅参考架构**——GPT-SoVITS、Applio、FreeVC; **第三档无价值**——本轮没有 (但 CosyVoice2 仅作“flow + vocoder 配方借鉴”, 其 Qwen2-0.5B LM 显然超预算 5 倍以上)。最关键的发现是 **OpenVoice v2 整套架构没有用任何 SSL 大模型** (没有 WavLM/HuBERT/ContentVec), 纯卷积+GRU+flow 设计, 参数 32.7M (其中推理相关的 ReferenceEncoder 0.76M、ResidualCouplingBlock flow 8.7M), 这正好填补了 TinyVC 在“说话人建模”这一块的空白。配合 F5-TTS 已有官方 ONNX 导出脚本的 Vocos 声码器 (13M), 本补充提出的 **v2 混合架构**把内存预算从 v1 的 ~85MB 调到 ~85MB (持平), 但**音质与相似度同时上调**。

v2 混合架构一句话总结: 保留 v1 的 TinyVC 内容编码器 (4.7M ConvNeXt-v2, 蒸馏 WavLM 第 4 层) + TinyVC SOLA 流式壳; 把 v1 的 kNN 检索替换为 OpenVoice v2 的 256-d ReferenceEncoder (5 个音色 × 256-d × FP16 = 2.5KB, 比 kNN 索引小 4000 倍); 在内容特征与声码器之间插入 OpenVoice v2 的 ResidualCouplingBlock flow (8.7M) 做学习式说话人解耦; 把 v1 的 DDSP 声码器替换为 F5-TTS 的 Vocos (13M, ONNX opset 17); F0 提取仍用 TinyVC 的 PitchEstimator (460K)。总 INT8 体积约 ~25MB (比 v1 ~18MB 多 7MB), 加运行时合计 ~85MB, 仍命中 100MB 硬约束。

二、六仓库横向对比 Six New Repos at a Glance

KICKER · ROUND 2 REPOSITORIES, SIDE BY SIDE

下表是本轮 6 个仓库的横向对比。判定标准沿用 v1: CPU/100MB 是否可行、是否有 ONNX 与量化、是否能流式推理、许可证是否商用友好、以及与 v1 主线 TinyVC 的关系。读者可以快速判断哪个仓库直接进运行时、哪个仅借鉴模块、哪个完全跳过。

仓库 Repo	许可证	参数量 Params	ONN X	流式	CPU/10 0MB	本方案定位 Our use
OpenVoice v2	MIT	32.7M (无 SSL)	否 No	否 (整段)	可行 ✓	替换 kNN + flow 借鉴
FreeVC	MIT	39M + 311M WavLM-L	否 No	否 No	不可行 ✗	flow 设计参考
GPT-SoVITS	MIT	~480M (BERT+HuBERT+AR)	部分	是 (RTF 0.526)	不可行 ✗	prompt-prefix + token pattern 借鉴
Applio	MIT	~95M + 360MB ContentVec	否 No	是 (block=250ms)	不可行 ✗	realtime shell + multi-vocoder 借鉴

仓库 Repo	许可证	参数量 Params	ONN X	流式	CPU/10 0MB	本方案定位 Our use
F5-TTS	代码 MIT 权重 NC	346M (333M DiT + 13M Vocos)	部分 (仅 Vo cos)	否 (整段)	不可行 xx	Vocos 声码器替换 DDSP
CosyVoice2	Apache 2.0	~520M (Qwen2-0.5B)	部分 (仅 flo w)	是 (KV-ca che)	不可行 x	flow 配方 + HiFT vocoder + campplus.onnx 借鉴

表 2-1 · 第二轮 6 仓库横向对比 · Round 2 cross-repo comparison

三、OpenVoice v2 —— 说话人编码器赢家

KICKER · NO SSL DEPENDENCY, PURE CONV+GRU+FLOW

仓库: myshell-ai/OpenVoice @ commit 74a1d147b, MIT 许可证（开源代码部分），预训练权重默认走 cc-by-nc-4.0 但 v2 的 LICENSE 文件已改为纯 MIT，可商用。磁盘占用 6.7MB（代码），权重运行时从 HuggingFace 拉取。关键发现：**OpenVoice v2 整个推理图没有用任何 SSL 大模型——它不需要 WavLM、HuBERT、ContentVec 中的任何一个。**这与其他所有候选仓库形成鲜明对比，是本调研中最重要的“另类设计”。

3.1 架构总览 Architecture

OpenVoice v2 是一个 VITS 风格的“tone color converter”，由四个子模块组成：(1) **PosteriorEncoder** (16 层 WaveNet, k=5, hidden=192, gin=256, ~8.8M) 作用于源 STFT mel-spec; (2) **ResidualCouplingBlock** normalizing flow (4 层 mean-only affine coupling, ~8.7M) 做说话人解耦——前向时把源说话人嵌入 src_se 映射到目标说话人嵌入 tgt_se 的反方向; (3) **Generator** HiFi-GAN 解码器 (upsample_rates=[8,8,2,2], 512 通道, 12 个 ResBlock1 @ kernels [3,7,11], ~14.5M) ; (4) **ReferenceEncoder** (6 层 2D-conv + GRU(128) + Linear(256) 作用于参考 mel-spec, ~0.76M) 输出 256 维 tone-color embedding, 可缓存为 se.pth（每音色 ~1KB）。总参数 32.7M, FP32 ~125MB, FP16 ~65MB, INT8 ~33MB。

3.2 与 TinyVC v1 的关系：替换 vs 借鉴

OpenVoice v2 整体作为运行时依赖**不合适**——它的 HiFi-GAN 解码器是非因果的，没有流式基础设施，无法命中 300–500ms 延迟目标。但它的**两个子模块可以直接嫁接到 TinyVC 主线上**：
(a) ReferenceEncoder 替换 TinyVC 的 kNN 检索——v1 用 kNN-VC 检索每帧源特征在目标特征库里的 top-4 余弦近邻, 5 个音色 × 1500 帧 × 768-d × FP16 = 11.5MB 索引。换成 OpenVoice 的 ReferenceEncoder: 5 个音色 × 256-d × FP16 = **2.5KB**（小 4000 倍! ），且每次推理只需做一次 FiLM-style 条件注入，无检索开销。OpenVoice 的 ReferenceEncoder 已经训练好（在 VCTK + 多语种数据上），无需重新训练即可使用。
(b) ResidualCouplingBlock flow 作为学习式说话人解耦层——v1 的 kNN 检索是“特征替换”（直接拿目标特征覆盖源特征），没有学习式映射。OpenVoice 的 4 层 mean-only affine flow 可以做“源嵌入 → 目标嵌入”的**可逆映射**，前向时 src_se 反向到 tgt_se，逆向时反向。8.7M 参数 + INT8 ~9MB，预期把说话人相似度从 85–90% 提升到 88–93%。

OpenVoice v2 的两个关键加分点：

- (1) **无 SSL 依赖**——其他所有候选（FreeVC、GPT-SoVITS、Applio、CosyVoice2）都至少要装载一个 90M+ 的 SSL 模型，OpenVoice 完全摆脱这个负担；
- (2) **ReferenceEncoder 输出 256-d 标量嵌入**——比 kNN-VC 的 [1, 768, T] 序列索引在存储/检索复杂度上低 4 个数量级，且天然支持任意 unseen 音色（只要 30 秒参考即可离线编码）。

四、其他 5 仓库快速判定 Other 5 Repos — Quick Verdicts

KICKER · WHY EACH ONE DOESN'T ENTER RUNTIME

4.1 FreeVC — WavLM-Large 依赖是死结

FreeVC 是 VITS 风格 one-shot VC，论文 SECS ~0.773（接近 GT）。但推理时**必须装载 WavLM-Large**（311M 参数，1.24GB FP32），单单这一个就超 100MB 预算 12 倍。代码停在 PyTorch 1.10 时代，无 ONNX/量化/流式。唯一可借鉴：**FreeVC 的 ResidualCouplingBlock flow（8.7M）**与 OpenVoice v2 的几乎一样——我们直接用 OpenVoice 的版本即可，FreeVC 整体跳过。

4.2 GPT-SoVITS — BERT-large + HuBERT 必装组合

GPT-SoVITS 的中文零样本 TTS+VC 质量是社区公认最好（~90–95% 相似度），但运行时**必须同时装载 chinese-roberta-wwm-ext-large BERT（325M）+ chinese-hubert-base（90M）**，加上 AR 主干（40M）合计 ~480M 参数 / 2GB FP32 / 1GB FP16——超 100MB 预算 20 倍。README 报告 Apple M4 上 RTF 0.526（处理 1 秒音频需 526ms），x86 还要慢 3-10 倍，远超 500ms 延迟目标。可借鉴：**HuBERT 1024-way k-means 语义 token vocabulary + 25Hz 帧率**作为内容编码器→声码器的通用接口；**interleaved prompt-prefix 说话人条件**（无需独立说话人编码器，直接把参考语义 token 拼到 AR 输入前缀）；**AR-on-tokens + 每层 KV-cache**模式；**onnx_export.py 4 子图拆分**作为量化边界模板。整体跳过。

4.3 Applio — RVC fork 但没解决 ContentVec 阻塞

Applio 是 RVC 的社区 fork，处于维护模式。相比上游 RVC 仅有**外观改进**：可插拔声码器（HiFi-GAN / MRF HiFi-GAN / RefineGAN / HiFi-GAN-NSF）、可插拔 F0 提取器（RMVPE / FCPE / Swift-F0 ONNX / CREPE-tiny）、**mp.spawn worker-process 实时壳**（热重载模型/索引/F0/embedder）。但**ContentVec ~360MB 这个核心阻塞原封未动**，无 DistilHuBERT 集成，无量化代码。可借鉴：**mp.spawn worker 进程模式**、**production-grade SOLA + phase vocoder crossfade**、**Faiss-on-torch 索引包装**。P2 阶段评估 RefineGAN 作为可选声码器。整体跳过。

4.4 F5-TTS — 权重非商用，但 Vocos 声码器可借鉴

F5-TTS 是 flow-matching TTS 的 SOTA 之一，论文 UTMOS 4.5（接近 GT 4.6），但权重为 **CC-BY-NC 非商用**（因 Emilia 数据集），且 Base 模型 ~346M 参数（333M DiT + 13M Vocos），FP32 1.4GB，超 100MB 预算 14 倍。推理 32 NFE × 2 CFG 在 CPU 上多秒每秒音频。可借鉴：**Vocos 声码器（13M，已有官方 ONNX 导出脚本 runtime/triton_trtllm/scripts/export_vocod**

er_to_onnx.py, opset 17, 24kHz/100-mel) ——这是 v2 混合架构的关键升级，直接替换 TinyVC 的 DDSP (4.6M 但音质薄)。Vocos 用 iSTFT 头直接输出频谱，避免 HiFi-GAN 的转置卷积，CPU 友好。INT8 后 ~7MB，是音质升级的性价比之选。**仅借鉴 Vocos 声码器与 EPSS+Sway+Euler-CFM 推理脚手架。**

4.5 CosyVoice2 — Apache 2.0 但 Qwen2-0.5B 超预算

CosyVoice2 是阿里的 TTS+VC 框架，Apache 2.0 许可证。4 阶段架构：BPE tokenizer + Whisper 语义 tokenizer + Qwen2-0.5B LM (24 层 896-d) + CausalConditionalCFM flow + HiFTGenerator 声码器。总参数 ~520M，FP32 ~2GB / FP16 ~1GB。README 报告 150ms 延迟仅在 GPU (Fun-CosyVoice3 + TensorRT-LLM)，CPU 上 Qwen2-0.5B AR 解码本身 RTF 1-3。中文 SS 75.7%，比 F5-TTS 高 (74.1%)，但英文 SS 65.9% 略低。可借鉴：(a)


CausalConditionalCFM flow-matching 配方 (10 步 Euler + cosine scheduler，可缩减到 ~3M)；(b) **HiFTGenerator 源滤波声码器** (缩减到 base_channels=256 后 ~3-5M，INT8 ~2-3MB，比 Vocos 更小)；(c) **token2wav 环形缓冲流式壳 + Hamming fade-in/out**；(d) **campplus.onnx** (192-d x-vector 说话人嵌入，~22MB，已 ONNX-ready) 作为 OpenVoice ReferenceEncoder 的备选；(e) **CausalConv1d + add_optional_chunk_mask** 流式原语。整体跳过 Qwen2-0.5B LM，仅借鉴 flow 配方 + 声码器 + 流式原语。

五、v2 混合架构推荐 v2 Hybrid Architecture

KICKER · THE NEW RECOMMENDED ARCHITECTURE

基于 11 个仓库的累计调研 (v1 五个 + v2 六个)，本节给出 **v2 混合架构** 的最终推荐。设计原则三条：(a) 保留 v1 已验证可跑的 TinyVC 主线 (编码器 + 流式壳 + F0)；(b) 用 OpenVoice v2 的“无 SSL 依赖”的说话人建模替换 v1 的 kNN 检索；(c) 用 F5-TTS 的 Vocos 声码器替换 v1 的 DDSP 声码器，提升音质丰满度。所有替换都在 INT8 后总体积 ~25MB 权重 + ~60MB 运行时 = ~85MB RAM 内完成。

5.1 数据流总览 Data Flow






图 5-1 · v2 混合架构数据流 · v2 hybrid architecture data flow

5.2 模块替换决策表 Module Replacement Decisions

模块 Module	v1 实现 v1 Implementation	v2 决策 v2 Decision	说明 Notes
内容编码器 Content Encoder	TinyVC ConvNeXt-v2 (4.7M)	保留 Keep	Apache 2.0, 18MB FP32 / 9MB INT8, 已 ONNX-ready
F0 提取器 Pitch Extrac tor	TinyVC PitchEstimator (460K)	保留 Keep	与编码器联合训练, 0.5MB, 语音场景 足够
说话人建模 Speaker Modeling	kNN-VC retrieval (5 × 11.5MB FP16 索引)	替换 Replace → OpenVoice v2 ReferenceE ncoder	0.76M, 5 × 256-d × FP16 = 2.5KB 总存储

模块 Module	v1 实现 v1 Implementation	v2 决策 v2 Decision	说明 Notes
说话人解耦 Speaker Disentanglement	(无, kNN 直接覆盖特征)	新增 Add → OpenVoice v2 ResidualCouplingBlock flow	8.7M, 9MB INT8, 学习式 affine 映射
声码器 Vocoder	TinyVC DDSP SourceNet + FilterNet (4.66M, 音质偏薄)	替换 Replace → F5-TTS Vocos	13M, 7MB INT8, ONNX-ready, iSTFT 头音质丰满
流式壳 Streaming Shell	TinyVC SOLA + torch.roll 环形缓冲	保留 Keep + 借鉴 Applio mp.spawn worker	P1 用 SOLA, P2 升级到 PocketTTS StreamingConv1d
VAD	WebRTC VAD (100KB)	保留 Keep	轻量, 已验证

表 5-1 · v1 → v2 模块替换决策 · v1 to v2 module replacement decisions

5.3 v2 vs v1 对比总结

维度 Dimension	v1 基线 v1 Baseline	v2 混合 v2 Hybrid	差异 Delta
权重体积 (INT8)	~18 MB	~25 MB	+7 MB (Vocos 替换 DDSP + flow 新增)
5 音色注册存储	11.5 MB (kNN 索引)	2.5 KB (256-d 嵌入)	-4600×
总常驻内存	~85-95 MB	~85 MB	持平 (Vocos 大小被存储节省抵消)
说话人相似度	~85-90%	~88-93%	+3-5% (学习式 flow > kNN 检索)
音质 (主观)	DDSP 偏薄	Vocos 丰满	显著提升 (iSTFT 头 vs 加法合成)
x86 端到端延迟	~370 ms	~370-420 ms	略增 (Vocos 推理 ~5ms)
ARM 延迟	~480 ms	~500-580 ms	临界, P2 需调小 chunk
许可证风险	Apache + Apache (TinyVC + PocketTTS 借鉴)	Apache + MIT + MIT (TinyVC + OpenVoice + F5-TTS 借鉴)	改善
训练成本	0 (用预训练 ckpt)	0 (用预训练 ckpt)	持平

表 5-2 · v1 vs v2 对比 · v1 vs v2 comparison

六、更新后的内存与质量预算 Updated Memory & Quality Budget

KICKER · WHERE EVERY MEGABYTE GOES IN v2

v2 混合架构在内存预算上与 v1 持平 (~85MB)，但每一 MB 的“含金量”更高：权重部分多了 7MB (Vocos 13M vs DDSP 4.66M，外加新增 flow 9MB)，但 5 音色注册存储从 11.5MB 降到 2.5KB (省 11.5MB)，刚好抵消。下表是 v2 常驻内存的逐项拆解：

组件 Component	体积 Size	说明 Notes
TinyVC encoder (INT8)	5 MB	ConvNeXt-v2 4.7M, 蒸馏 WavLM
OpenVoice ReferenceEncoder (INT8)	1 MB	0.76M, 256-d 说话人嵌入
OpenVoice ResidualCoupling flow (INT8)	9 MB	8.7M, 4 层 mean-only affine

组件 Component	体积 Size	说明 Notes
F5-TTS Vocos vocoder (INT8)	7 MB	13M, iSTFT 头, ONNX opset 17
TinyVC PitchEstimator (INT8)	0.5 MB	460K, 与编码器联合训练
5 个音色嵌入 (256-d FP16)	2.5 KB	$5 \times 256 \times 2$ bytes, 几乎为零
音频环形缓冲 (SOLA)	8 MB	block + crossfade + sola_search + $2 \times \text{last_delay}$
激活张量峰值	15 MB	block=1920 单帧前向 + flow 中间张量
ONNXRuntime 工作内存	20 MB	intra=2, inter=1, MLAS (x86) / XNNPACK (ARM)
Python + 标准库	20 MB	基础开销
WebRTC VAD + 工具	2 MB	轻量依赖
合计 Total	~87 MB	命中 100MB 目标, 余量 13MB

表 6-1 · v2 常驻内存拆解 · v2 RSS breakdown

6.2 质量预期 Quality Expectations

v2 的质量提升主要来自三处：(a) OpenVoice ResidualCoupling flow 把 kNN 的“特征覆盖”升级为“学习式 affine 映射”，相似度从 85–90% 提升到 88–93%；(b) F5-TTS Vocos 用 iSTFT 头直接输出频谱，比 DDSP 的加法合成音质丰满，MOS 提升 ~0.2-0.3；(c) OpenVoice ReferenceEncoder 输出 256-d 全局嵌入，避免 kNN 在未见音素上的 fallback 问题。与 GPT-SoVITS/F5-TTS/CosyVoice2 的 90–95% 相比仍有 2-7% 差距，但这是以 1/20 的内存和 1/5 的延迟换来的，性价比合理。

七、更新后的 P0/P1/P2 Checklist Updated Checklist

KICKER · NEW TASKS FOR v2 HYBRID

本节在 v1 checklist 基础上新增 v2 相关任务。v1 的 P0/P1/P2 任务仍然有效（保持不变），本表只列新增或修改的任务。优先级含义：P0 阻塞性必做、P1 显著性能收益、P2 锦上添花。

编号 ID	任务 Task	预估 Effort	验证标准 Verification
P0-6 (NE W)	Clone OpenVoice v2 + 下载 ckpt, 提取 ReferenceEncoder + ResidualCouplingBlock 权重	1 h	能加载 se.pth (256-d 嵌入) + flow 权重, 单独 forward 测试通过
P0-7 (NE W)	采集 5 个音色 30s 参考, 用 OpenVoice ReferenceEncoder 离线编码为 se_0.pth ... se_4.pth	0.5 h	5 个 .pth 文件, 每个 256-d, total < 5 KB
P0-8 (NE W)	Clone F5-TTS, 运行 export_vocoder_to_onnx.py 导出 Vocos.onnx	1 h	Vocos.onnx 存在, ~13 MB, ONNX opset 17
P1-7 (NE W)	将 OpenVoice ReferenceEncoder + ResidualCoupling flow 加入推理图	3 h	替换原 kNN 路径, 端到端 forward 通过, 音质可听
P1-8 (NE W)	替换 DDSP 为 F5-TTS Vocos 声码器	2 h	Vocos.int8.onnx 加载通过, 音质主观丰满度提升

编号 ID	任务 Task	预估 Effort	验证标准 Verification
P1-9 (NEW)	重新 benchmark: RSS / 延迟 / 相似度	1 h	RSS < 100MB, E2E < 500ms, 相似度 > 88%
P2-7 (NEW)	尝试 CosyVoice2 HiFTGenerator (base_channels=256) 替换 Vocos	6 h	体积更小 (~3-5MB INT8), 音质与 Vocos 对比报告
P2-8 (NEW)	尝试 CosyVoice2 campplus.onnx 替换 OpenVoice ReferenceEncoder	4 h	192-d x-vector, 已 ONNX-ready, 对比 256-d 嵌入质量
P2-9 (NEW)	借鉴 CosyVoice2 token2wav 环形缓冲替换 TinyVC SOLA	6 h	算法延迟 < 200ms, 无 SOLA 拼接痕迹
P2-10 (NEW)	评估 GPT-SoVITS interleaved prompt-prefix 模式	4 h	把参考语义 token 拼到内容前缀, 无需独立 speaker enc

表 7-1 · v2 新增 checklist (v1 任务仍有效) · v2 new tasks

总计新增工时约 28.5 小时 (P0+2.5h, P1+6h, P2+20h)。若用户希望尽快看到 v2 效果，建议先做 P0-6/7/8 + P1-7/8/9 共 8.5 小时，即可拿到 v2 混合架构的端到端可用版本，与 v1 做主观对比。

八、质量 vs 体积权衡总结 Quality vs Size Trade-off

KICKER · WHERE v2 SITS ON THE PARETO CURVE

把 11 个仓库按“说话人相似度 vs INT8 权重体积”画一张帕累托曲线，可以清楚看到 v2 混合架构的位置：

方案 Option	相似度/质量	INT8 权重	100MB 可行	说明 Notes
TinyVC (v1 基线)	~85-90%	~18 MB	✓ ✓	最轻, 相似度偏低
v2 混合架构	~88-93%	~25 MB	✓ ✓	本方案推荐
RVC v2 (ContentVec 替换 DistilHuBERT)	~90-95%	~65 MB	✗ 临界	需要切到 DistilHuBERT
OpenVoice v2 (整模型)	~3.6-3.8 MOS	~33 MB	✗	无流式, 非因果 HiFi-GAN
Applio (DistilHuBERT 替换 ContentVec)	~90-95%	~65 MB	✗ 临界	同 RVC
FreeVC	~3.7-3.8 MOS	~310 MB	✗✗	WavLM-Large 阻塞
GPT-SoVITS	~90-95%	~480 MB	✗✗	BERT+HuBERT 必装
CosyVoice2	~75% SS	~520 MB	✗✗	Qwen2-0.5B LM 阻塞
F5-TTS	~4.5 UTMOS	~346 MB	✗✗	NC 许可证, DiT 太大
Fish-Speech	n/a	~1 GB+	✗✗✗	NC 许可证, DualAR 4B

表 8-1 · 帕累托曲线 · Quality vs INT8 weight size Pareto curve

结论：**v2 混合架构处于“100MB 可行”这一档的最优位置**——相比 v1 TinyVC 基线，相似度 +3-5%、音质显著提升；相比 RVC（DistilHuBERT 路径），权重小 2.6 倍、相似度相当；相比 GPT-SoVITS / CosyVoice2 / F5-TTS / Fish-Speech，权重小 12-40 倍，相似度仅低 2-7%。对于“轻量级实时 CPU 场景”，这是当前能做到的**最佳工程平衡**。

补充报告结束 · Generated by Z.ai · 2026.10 · 数据来源: myshell-ai/OpenVoice, OlaWod/FreeVC, RVC-Boss/GPT-SoVITS, IAHispano/Applio, SWivid/F5-TTS, FunAudioLLM/CosyVoice