

SUPPLEMENT · ROUND 3 · v3 INCREMENTAL UPGRADE

实时 CPU 语音转换 v3 增量升级补充

Round 3 Supplement — Pareto Curve Confirmed, One Module Swap

本 v3 补充报告覆盖 Round 3 调研的 6 个新仓库：**Spark-TTS**、**IndexTTS**（B 站）、**MaskGCT**（Amphion）、**Orpheus-TTS**、**StyleTTS-2**、**Piper**。在分析了累计 17 个仓库（Round 1 五个 + Round 2 六个 + Round 3 六个）后，本报告确认 **v2 混合架构** 处于“CPU ≤100MB + 实时 + 优 VC 质量”帕累托曲线的最优点。本轮调研唯一的增量升级机会：把 OpenVoice v2 的 256-d ReferenceEncoder（0.76M）替换为 Spark-TTS BiCodec SpeakerEncoder（ECAPA-TDNN c512 + PerceiverResampler + ResidualFSQ, 6-12M, 512-d + 48 字节 FSQ 离散码），预期相似度 +1-2%、内存 +4MB（仍在 100MB 内）。

17

累计分析仓库 / Total repos

6

本轮新调研 / This round

1

可借鉴升级模块 / Upgrade modules

+1-2%

v3 相似度提升 / SIM uplift

一、Round 3 执行摘要 Executive Summary

KICKER · 17 REPOS IN, V2 HYBRID CONFIRMED OPTIMAL

在 Round 1 和 Round 2 分别调研 5 个和 6 个仓库后，v2 混合架构（TinyVC 编码器 + OpenVoice v2 ReferenceEncoder + ResidualCoupling flow + F5-TTS Vocos 声码器）作为推荐方案确立。Round 3 进一步调研了 6 个 2024-2025 年新发布的 SOTA 仓库，目标只有一个——看是否有仓库能整体替换或显著改进 v2 混合架构。

结论很清晰：没有任何一个仓库能在 100MB CPU + 实时 + 优 VC 质量三个硬约束下整体替换 v2。SOTA 仓库（Spark-TTS、IndexTTS、MaskGCT、Orpheus-TTS）普遍使用 LLaMA-3.2-3B / Qwen2.5-0.5B / GPT-2-0.8B 等大 LLM 作为主干，参数量从 1.5B 到 3.0B 不等，超出 100MB 预算 15-30 倍。MaskGCT 虽然是非自回归（NAR）架构，理论上可以并行解码，但 25+36 步反向扩散仍需 122 次前向，CPU 上完全不可实时。StyleTTS-2 是 TTS 不是 VC，其 StyleEncoder 与 OpenVoice v2 ReferenceEncoder 架构等同，无增量价值。Piper 极致轻量（每音色 60-100MB ONNX，Pi 4 上 RTF 0.3-0.5）但不支持零样本克隆——只能用预训练音色 ID，必须为每个新音色做 1000 epoch 微调，与本项目的“5 音色 × 30s 参考”硬需求不兼容。

v3 增量升级的核心发现：Spark-TTS 的 BiCodec SpeakerEncoder（ECAPA-TDNN c512 + PerceiverResampler(32 latents) + ResidualFSQ(levels=[4,4,4,4,4,4])) 是唯一对 v2 有真实增量价值的模块——输出 512-d 说话人嵌入（vs OpenVoice v2 的 256-d），且 ResidualFSQ 把嵌入量化为 48 字节离散码（6×8 bits），可用于哈希索引快速查找，预期相似度 +1-2%、内存 +4MB。其他 5 个仓库全部“仅参考架构”，不进入运行时。

二、Round 3 六仓库横向对比 Six Repos at a Glance

KICKER · ALL INFEASIBLE AS WHOLE-SYSTEM REPLACEMENTS

仓库 Repo	许可证	参数量	ONN X	流式	CPU/100MB	本方案定位 Our use
Spark-TTS	Apache 2.0	~830-890M (Qwen2.5-0.5B + Wav2Vec2-L)	否 No	否 (GPU-only)	不可行 ✗	借鉴 BiCodec SpeakerEncoder
IndexTTS (B站)	非商用 + 商用悬崖	~1.7B (GPT-2 0.8B + w2v-bert-2.0 600M)	部分 (TRT)	是 (GPU-only)	不可行 ✗✗	Conformer+Perceiver speaker enc 备选
MaskGCT (Amphion)	MIT	~1.49B (w2v-bert-2.0 600M + 4 模型)	否 No	否 (NAR 但 122 次前向)	不可行 ✗✗	完全跳过
Orpheus-TTS	Apache 2.0	~3.0B (Llama-3.2-3B + SNAC 30M)	GGU F Q4	是 (CPU 但慢)	不可行 ✗✗	SNAC 编解码可关注，整体跳过
StyleTTS-2	MIT	~45-55M (主模型)	否 No	否 (5 步扩散)	临界	TTS 非 VC, StyleEncoder 与 v2 等同, 跳过
Piper	MIT	~15-25M/音色 (VITS)	是 (官方 ONNX)	是 (Pi4 RTF 0.3-0.5)	可行但无 VC	借鉴 SpeechStreamer 流式算法

表 2-1 · Round 3 六仓库横向对比 · Round 3 cross-repo comparison

三、Spark-TTS BiCodec SpeakerEncoder —— 唯一增量升级

KICKER · ECAPA-TDNN + PERCEIVER + RESIDUAL FSQ

仓库：github.com/SparkAudio/Spark-TTS @ commit 2f1ea988, Apache 2.0。整体架构是 Qwen2.5-0.5B LLM + BiCodec 编解码器，总参数 ~830-890M，超 100MB 预算 8 倍。但 Spark-TTS 的 BiCodec 模块里有一个独立的 SpeakerEncoder，由三个子模块组成，可以单独导出使用：

- (1) **ECAPA-TDNN c512** (~5M 参数) —— 当前 SOTA 说话人编码器架构，比 OpenVoice v2 ReferenceEncoder 的 6-layer 2D-conv + GRU(128) 设计更强。输出 512-d 时序特征 [B, T, 512]。
- (2) **PerceiverResampler(num_latents=32)** (~1M 参数) —— 把变长时序特征压缩为 32 个 512-d latent token，等价于一个学习式注意力池化，比简单 mean-pooling 保留更多信息。
- (3) **ResidualFSQ(levels=[4,4,4,4,4,4])** (~0.5M 参数) —— 把每个 latent token 量化为 6 个 4 选 1 的离散码 (共 6×2 bits = 12 bits/token，48 字节/voice)。FSQ 比 VQ 的优势是无须 codebook 训练、量化误差更小、可哈希检索。

3.1 为什么这是 v2 的合理升级

v2 用 OpenVoice v2 的 ReferenceEncoder 输出 256-d 浮点嵌入，存在两个问题：(a) 256-d 是“全局均值池化”后的向量，丢失了说话人的时序细节；(b) 浮点嵌入只能做余弦相似度比较，无法做精确哈希检索 (O(1) vs O(N))。Spark-TTS BiCodec SpeakerEncoder 输出 512-d Perceiver-resampled 嵌入，且经过 FSQ 量化，既保留了时序信息 (Perceiver)，又可以用 48 字节 FSQ 码做哈希索引 (适合 5 个固定音色的 O(1) 查找)。INT8 后体积 ~5MB (vs OpenVoice v2 1MB，多 4MB)，仍在 100MB 预算内。

3.2 预期质量与体积对比

方案 Option	参数量	输出维度	量化形式	INT8 体积	预期相似度
OpenVoice v2 ReferenceEncoder (v2)	0.76 M	256-d	浮点	1 MB	~88-93%
Spark-TTS BiCodec SpeakerEncoder (v3)	6-12 M	512-d + Perceiver	FSQ 48B 离散码	~5 MB	~90-94% (估)
IndexTTS Conformer+Perceiver (备选)	3-7 M	1024-d	浮点	~3 MB	~89-93% (估)

表 3-1 · 说话人编码器升级对比 · Speaker encoder upgrade comparison

为什么 Spark-TTS BiCodec 而不是 IndexTTS Conformer? IndexTTS 许可证为**非商用 + 商用悬崖** (100M MAU 或 10亿 RMB 营收触发限制)，即使只借鉴模块也有合规风险。Spark-TTS 是纯 Apache 2.0，可直接借鉴代码与权重。另外 IndexTTS 的 ConformerEncoder 需要依赖 w2v-bert-2.0 (600M) 作为输入特征，而 Spark-TTS 的 ECAPA-TDNN 直接吃 mel-spec，与现有 TinyVC 编码器输出兼容。

四、其他 5 仓库快速判定 Other 5 Repos — Quick Verdicts

KICKER · WHY EACH ONE DOESN'T ENTER RUNTIME

4.1 IndexTTS (B 站) —— 修正前一轮的认知误区

此前业界普遍猜测 IndexTTS 是“RVC-style 检索增强”，子代理全仓 grep `faiss|knn|retriev|index_search|feature_index` 零匹配——“Index”其实是 B 站“Index Speech”团队名 (`indexspeech@bilibili.com`)，与检索索引无关。IndexTTS 是标准 GPT-2 风格自回归 TTS，0.8B 参数 GPT-2 + w2v-bert-2.0 (600M) + BigVGAN-v2 + UViT DiT flow。总 ~1.7B 参数，FP32 6.8GB / INT8 1.7GB，**超 100MB 预算 17-68 倍**。许可证是 bilibili Model Use License，非商用 + 商用悬崖，比 F5-TTS 的 CC-BY-NC 更严格，不可借鉴代码进入商用系统。整体跳过。

4.2 MaskGCT —— SOTA 质量但 CPU 完全不可行

MaskGCT (Amphion 框架下，MIT 许可证) 是非自回归 (NAR) 掩码生成式 codec transformer，论文报告 SeedTTS test-zh SIM **0.805 (超过 ground truth!)** ——在 17 个仓库中**质量第一**。但架构上是 4 个模型串联：Wav2Vec2-BERT 2.0 (600M) 做语义 tokenizer + MaskGCT_T2S (470M, 16 层 LLaMA) + MaskGCT_S2A_l1ayer (165M) + MaskGCT_S2A_full (170M) + Vocos 解码器。推理需 $25+36=122$ 次 16 层 LLaMA 全序列前向 (含 CFG 翻倍)，CPU 上每秒音频需 30-60 秒计算，完全不可实时。整体跳过，仅作未来 GPU 方案参考。

4.3 Orpheus-TTS —— Llama-3.2-3B + SNAC, 路线图有 150M 变体

Orpheus-TTS (Apache 2.0) 基于 Llama-3.2-3B + SNAC 24kHz 编解码器，社区 orpheus-cpp 包提供 Q4 GGUF CPU 路径 (Llama-3.2-3B Q4 = 1.8GB)，但 30-50 tok/s 的 CPU 解码速度下首音延迟 600ms-1.5s，RTF 1-3×，**超 500ms 预算**。README 路线图提到未来会发布 150M/400M/1B 变体 (line 163)，如果 400M 变体发布且支持 GGUF Q4，预计能压到 ~250MB INT4 内存、~400ms 延迟，可能成为本项目的“未来方案 2”——目前先观望，本轮跳过。

4.4 StyleTTS-2 —— TTS 非 VC，StyleEncoder 与 v2 等同

StyleTTS-2 (MIT, ~45-55M 主模型) 在 LJSpeech 上 MOS 4.14 (超过人类 4.05)，但**本质是 TTS 不是 VC**——要把源音频做 ASR 转写再合成，丢失源 prosody 并增加 2-5s 延迟。其 StyleEncoder 与 OpenVoice v2 ReferenceEncoder 架构等同 (都是 CNN-ResBlk + AdaptiveAvgPool 的全局嵌入)，**无增量价值**。5 步祖扩散采样器在 CPU 上需 2-5s，无法实时。整体跳过。

4.5 Piper —— 极致轻量但无零样本克隆能力

Piper (MIT, VITS 蒸馏版，每音色 60-100MB ONNX, Pi 4 上 RTF 0.3-0.5) 是**纯 TTS**，推理路径里没有任何零样本克隆机制——speaker 条件只是 `nn.Embedding(n_speakers, 512)` 整数 ID 索引，加新音色需 1000 epoch 微调。**不兼容“5 音色 × 30s 参考”硬需求**。但可借鉴：(a) SpeechStreamer (`infer_onnx_streaming.py:76-108`) 45-mel-frame 流式算法可直接套到我们的

streaming.py 上，比 SOLA 更成熟；(b) C++ ONNXRuntime 部署模式作为未来跨平台二进制打包参考。**整体跳过**，仅借鉴 SpeechStreamer 算法。

五、v3 混合架构推荐 v3 Hybrid Architecture

KICKER · V2 + 1 MODULE SWAP, ALL ELSE UNCHANGED

v3 混合架构在 v2 基础上仅做一个**模块替换**——把 OpenVoice v2 ReferenceEncoder (256-d, 0.76M, INT8 1MB) 换成 Spark-TTS BiCodec SpeakerEncoder (512-d + Perceiver + FSQ, 6-12M, INT8 ~5MB)。其余 5 个模块 (TinyVC 内容编码器、TinyVC PitchEstimator、OpenVoice v2 ResidualCoupling flow、F5-TTS Vocos 声码器、TinyVC SOLA 流式壳) 全部保留不变。这是一个**外科手术式的增量升级**，主要风险是 Spark-TTS BiCodec SpeakerEncoder 需要从 Spark-TTS 源码导出 ONNX (无现成导出脚本，需自行写 ~50 行)，并验证 512-d 嵌入对 v2 flow 的兼容性。

5.1 v3 模块替换决策表

模块 Module	v2 实现 v2 Implementation	v3 决策 v3 Decision	说明 Notes
内容编码器 Content Encoder	TinyVC ConvNeXt-v2 (4.7M)	保留 Keep	17 个仓库中无更优选择
F0 提取器 Pitch Extractor	TinyVC PitchEstimator (460K)	保留 Keep	与编码器联合训练, 0.5MB
说话人编码器 Speaker Encoder	OpenVoice v2 ReferenceEncoder (256-d, 0.76M)	替换 Replace → Spark-TTS BiCodec SpeakerEncoder (512-d + FSQ, 6-12M)	ECAPA-TDNN + Perceiver + ResidualFSQ, INT8 ~5MB
说话人解耦 Speaker Disentanglement	OpenVoice v2 ResidualCouplingBlock flow (8.7M)	保留 Keep	学习式 affine 映射, 9MB INT8
声码器 Vocoder	F5-TTS Vocos (13M, ONNX opset 17)	保留 Keep	iSTFT 头, 7MB INT8, 比 DDSP 丰满
流式壳 Streaming Shell	TinyVC SOLA + torch.roll 环形缓冲	保留 Keep + 借鉴 Piper SpeechStreamer	P2 阶段评估 45-mel-frame 算法替代 SOLA
VAD	WebRTC VAD (100KB)	保留 Keep	轻量已验证

表 5-1 · v2 → v3 模块替换决策 · v2 to v3 module replacement decisions

5.2 v1 → v2 → v3 演化总结

维度 Dimension	v1 基线	v2 混合	v3 增量	差异 Delta
内容编码器 (INT8)	5 MB	5 MB	5 MB	保留 TinyVC ConvNeXt
说话人编码器 (INT8)	kNN 索引 12 MB	1 MB (OpenVoice 256-d)	5 MB (Spark BiCodec 512-d)	+4 MB

维度 Dimension	v1 基线	v2 混合	v3 增量	差异 Delta
说话人解耦 flow (INT8)	无	9 MB (OpenVoice Residual)	9 MB	保留 v2
声码器 (INT8)	5 MB (TinyVC DDSP)	7 MB (F5 Vocos)	7 MB	保留 v2
5 音色注册存储	12 MB (kNN)	2.5 KB (256-d FP16)	240 B (FSQ 48B × 5)	-10× vs v2
总常驻内存	~85-95 MB	~85 MB	~89 MB	+4 MB (仍命中)
说话人相似度	~85-90%	~88-93%	~90-94%	+1-2% (估)
音质 (主观)	DDSP 薄	Vocos 丰满	Vocos 丰满	持平 v2
x86 端到端延迟	~370 ms	~370-420 ms	~380-430 ms	略增 (~10ms)
许可证风险	Apache	Apache+MIT	Apache+MIT+MIT	Spark BiCodec 也是 Apache

表 5-2 · v1 → v2 → v3 演化对比 · v1 to v2 to v3 evolution

六、v3 新增 Checklist v3 New Checklist

KICKER · 6 NEW TASKS (V1+V2 TASKS STILL VALID)

本节在 v2 checklist 基础上新增 v3 相关任务。v1 + v2 的所有 P0/P1/P2 任务仍然有效，本表只列**新增或修改**的任务。

编号 ID	任务 Task	预估 Effort	验证标准 Verification
P0-9 (NEW)	Clone Spark-TTS + 提取 BiCodec SpeakerEncoder (ECAPA-TDNN + Perceiver + ResidualFSQ) ONNX	2 h	speaker_encoder_spark.onnx 存在, ~6-12M 参数, 512-d 输出 + FSQ 码可解码
P0-10 (NEW)	采集 5 音色 30s 参考, 用 BiCodec SpeakerEncoder 离线编码为 5 个 48 字节 FSQ 码	0.5 h	5 个 .fsq 文件 (48 字节 each) 存在
P0-11 (NEW)	验证 5 个 FSQ 码互不相同 (理论上 2^48 空间, 几乎不可能冲突)	0.2 h	5 个码均不同, 哈希索引 O(1) 查找可用
P1-10 (NEW)	将 BiCodec SpeakerEncoder 加入 v3 推理图, 替换 v2 的 OpenVoice ReferenceEncoder	3 h	v3 推理端到端通过, 输出可听
P1-11 (NEW)	重新 benchmark v3: RSS / 延迟 / 相似度, 与 v2 对比	1 h	RSS < 100MB, E2E < 500ms, 相似度 > 90%
P2-11 (NEW)	借鉴 Piper SpeechStreamer 45-mel-frame 算法替代 TinyVC SOLA	4 h	算法延迟 < 250ms, 无 SOLA 拼接痕迹
P2-12 (NEW)	评估 IndexTTS Conformer+Perceiver (商用风险, 仅参考)	2 h	作为 future-2 备选, 不进入运行时
P2-13 (NEW)	关注 Orpheus-TTS 路线图 150M/400M 变体发布	持续 ongoing	若发布 400M + GGUF Q4, 重新评估是否整体替换

表 6-1 · v3 新增 checklist · v3 new tasks

总计 v3 新增工时约 12.5 小时 (P0+2.7h, P1+4h, P2+6h)。若用户希望尽快看到 v3 效果，建议先做 P0-9/10/11 + P1-10/11 共 6.7 小时，即可拿到 v3 端到端可用版本，与 v2 做主观盲听 A/B 测试。

七、17 仓库帕累托曲线最终版 Final Pareto Curve

KICKER · WHERE v3 SITS ON THE 17-REPO PARETO CURVE

累计调研 17 个仓库后，完整的“说话人相似度 vs INT8 权重体积”帕累托曲线如下：

方案 Option	相似度/质量	INT8 权重	100MB 可行	说明 Notes
TinyVC (v1 基线)	~85-90%	~18 MB	✓ ✓	最轻, 相似度偏低
v2 混合架构	~88-93%	~25 MB	✓ ✓	Round 2 推荐
v3 增量升级	~90-94%	~29 MB	✓ ✓	Round 3 推荐
RVC v2 (DistilHuBERT)	~90-95%	~65 MB	✗ 临界	需要切到 DistilHuBERT
OpenVoice v2 (整模型)	~3.6-3.8 MOS	~33 MB	✗	无流式
Applio (DistilHuBERT)	~90-95%	~65 MB	✗ 临界	同 RVC
StyleTTS-2 (整模型)	~4.14 MOS	~22 MB	✗ 临界	TTS 非 VC
FreeVC	~3.7-3.8 MOS	~310 MB	✗✗	WavLM-Large 阻塞
Piper	n/a (无零样本)	~62 MB	✗ (无 VC)	极致轻但无克隆能力
GPT-SoVITS	~90-95%	~480 MB	✗✗	BERT+HuBERT 必装
CosyVoice2	~75% SS	~520 MB	✗✗	Qwen2-0.5B LM
F5-TTS	~4.5 UTMOS	~346 MB	✗✗	NC 许可, DiT 太大
Spark-TTS	n/a (TTS)	~830 MB	✗✗	Qwen2.5-0.5B + Wav2Vec2-L
IndexTTS	~73% SS	~1.7 GB	✗✗	GPT-2 0.8B + w2v-bert-2.0
MaskGCT	~0.805 SIM	~1.5 GB	✗✗✗	122 次前向, CPU 不可实时
Orpheus-TTS	n/a	~1.8 GB (Q4 GGUF)	✗✗	Llama-3.2-3B
Fish-Speech	n/a	~1 GB+	✗✗✗	NC 许可, DualAR 4B

表 7-1 · 17 仓库完整帕累托曲线 · Full 17-repo Pareto curve

最终结论：在 17 个调研仓库中，v3 增量升级处于“100MB 可行”档的最优位置——相比 v1 基线相似度 +5-9%、音质显著提升；相比 v2 相似度 +1-2%、内存 +4MB；相比 RVC 路径（DistilHuBERT）权重小 2.2 倍、相似度相当；相比 GPT-SoVITS / CosyVoice2 / MaskGCT / Orpheus-TTS / Fish-Speech 等大 LLM 路径，权重小 15-60 倍，相似度仅低 2-5%。对于“轻量级实时 CPU 场景”，v3 是当前能做到的最佳工程平衡，且为后续升级留有余地——未来若 Orpheus-TTS 发布 400M GGUF 变体，可整体替换为方案 2；若 MaskGCT 蒸馏版发布，可整体替换为方案 3。

v3 补充报告结束 · Generated by Z.ai · 2026.10 · 累计调研 17 个仓库 · Round 3 数据来源：SparkAudio/Spark-TTS, index-tts/index-tts, open-mmlab/Amphion (MaskGCT), canopyai/Orpheus-TTS, yl4579/StyleTTS2, rhasspy/piper